

**A G H**

**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W  
KRAKOWIE**

**WYDZIAŁ ELEKTROTECHNIKI, AUTOMATYKI,  
INFORMATYKI I INŻYNIERII BIOMEDYCZNEJ**

KATEDRA AUTOMATYKI I ROBOTYKI

**Praca dyplomowa magisterska**

*Sprzętowo-programowy system wizyjny do detekcji  
obiektów z wykorzystaniem termowizji*

*Hardware-software vision system for object detection with  
the use of thermovision.*

Autor: Tomasz Kańka

Kierunek studiów: Automatyka i Robotyka

Opiekun pracy: dr inż. Tomasz Kryjak

Kraków, 2018

*Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, videogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej « sądem koleżeńskim ».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobistnie i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.*

*Serdecznie dziękuję siostrze i ojcu za  
urzyczenie swojego ciepła.*



## **Streszczenie**

**Słowa kluczowe:**

**Abstract**

**Keywords:**



# **Spis treści**

<b>1. Wprowadzenie .....</b>	9
1.1. Cel pracy .....	10
1.2. Struktura pracy .....	11
<b>2. System multispektralny .....</b>	13
2.1. Podczerwień .....	13
2.2. Kamera termowizyjna.....	14
2.2.1. Sensor podczerwieni.....	14
2.2.2. Kamera termowizyjna FLIR Lepton.....	15
2.3. Rejestracja obrazu multispektralnego.....	16
2.3.1. Model geometryczny .....	18
2.3.2. Kalibracja .....	19
<b>3. Algorytmy detekcji pieszych .....</b>	23
3.1. Ustalenie regionu zainteresowań .....	23
3.2. Wyodrębnienie cech .....	24
3.3. Klasyfikator .....	25
<b>4. Wykorzystanie FPGA w analizie obrazu .....</b>	27
4.1. Zynq-7000 .....	28
4.2. Interfejs AXI.....	28
<b>5. Przegląd literatury .....</b>	31
5.1. Koledzy z Poznania .....	31
5.2. Stereotermowizja .....	32
5.3. Podejście sprzętowo-programowe. Stereowizja dla robotów .....	33
5.4. Podejście sprzętowo-programowe. System wspomagania kierowcy.....	34
5.5. Wzorzec probabilistyczny .....	34
5.6. Poprzednie prace .....	35

<b>6. Proponowany system wizyjny .....</b>	37
6.1. koncepcja systemu.....	37
6.2. Moduły w PL.....	39
6.3. Wykorzystanie AXI-Stream do transmisji sygnału wideo. ....	39
6.4. AXI VDMA.....	40
6.5. Opis modułów w PL.....	41
6.5.1. Kontroler kamery IR.....	41
6.5.2. Transformata projekcyjna.....	42
6.5.3. Interpolacja dwuliniowa .....	42
6.5.4. Łączenie strumieni.....	43
6.5.5. Koloryzacja i nakładanie .....	44
6.5.6. Obramowanie wyników.....	44
6.5.7. Moduł DPM.....	44
6.6. System procesorowy .....	45
6.7. Proces kalibracji .....	45
6.8. HOG i SVM.....	46
6.9. Wyniki .....	47
<b>7. Podsumowanie i dalsze kierunku rozwoju.....</b>	49

# 1. Wprowadzenie

Cyfrowa analiza obrazów znalazła szerokie zastosowanie w wielu dziedzinach życia. Dzięki niej możliwe jest automatyczne uzyskanie istotnych dla użytkownika informacji. Przez ostatnie kilkadziesiąt lat opracowano tysiące różnych technik i algorytmów wyspecjalizowanych do określonych zadań np. leśne fotopułapki do badania zachowań i migracji zwierząt, systemu kontroli jakości i przebiegu procesu przemysłowego, metody kontroli dostępu poprzez rozpoznawanie twarzy m.in. w smartfonach, algorytmu analizy zdjęć satelitarnych ziemi umożliwiające prognozowanie pogody, sterowanie ruchem drogowym na podstawie obrazu z kamer zamontowanych nad skrzyżowaniami, a także systemy do badania przekroju żołędzia pozwalające określić czy jest dobrym kandydatem na sadzonkę.

Wzrok ludzki operuje w pewnym zakresie promieniowania elektromagnetycznego zwanego światłem widzialnym. Dzisiejsza technologia daje możliwość rejestracji obrazów wykraczających poza to widmo. Kamery termowizyjne stają się coraz tańsze i przez to bardziej popularne. Dostarczają one информацию o temperaturze obserwowanych obiektów. Jest to coraz częściej wykorzystywane np. w weterynarii do określenia miejsc urazów zwierząt, w przemyśle do kontroli jakości artykułów spożywczych, w budownictwie do analizy strat cieplnych w budynkach, w systemach wspomagania kierowcy, przez ratowników do odnajdywania zasypanych ludzi w gruzowiskach, straż graniczną do monitorowania granic, przez wojsko do odnajdywania celów i zagrożeń podczas misji m.in. z wykorzystaniem dronów. [1].

Większość systemów wizyjnych służących do rozpoznawania przechodniów jest oparta o analizę obrazów z zakresu światła widzialnego, bądź podczerwieni. W przypadku światła widzialnego można uzyskać bardzo dobre wyniki pod warunkiem że wyszukiwane obiekty są dobrze oświetlone i wyróżniają się swoim kolorem od tła. Podczerwień, a szczególnie termowizja, umożliwia detekcję w warunkach nocnych i ograniczonej widoczności. Oba podejścia mają swoje wady i zalety, które wzajemnie się uzupełniają np. duże nasłonecznienia powoduje, że tło termiczne staje się dużo wyższe co utrudnia wyodrębnienie pieszego, natomiast daje idealne warunki do uzyskania dobrej jakości obrazu w zakresie widzialnym [2]. Połączenie tych dwóch obrazów daje możliwość uzyskania jeszcze lepszej skuteczności rozpoznawania ludzi. W pracy

[3] autorzy nazywają ten rozszerzony format jako RGBT ("Red-Green-Blue-Thermal"), natomiast inna praca jako analizę wielospektralną (ang. *Multispectral*) [4], albo po prostu jako połączony obraz z kamery termowizyjnej i wizyjnej [2].

Skuteczna detekcja obiektów często wymaga dużego zapotrzebowania na zasoby obliczeniowe. W wielu przypadkach nie da się uzyskać satysfakcyjującej wydajności – tak by można było uznać system za działający w czasie rzeczywistym – wykorzystując jedynie typowy komputer wyposażony w procesor ogólnego przeznaczenia. Stosuje się zatem różne metody akceleracji obliczeń. Karty graficzne (GPU ang. *graphics processing unit*) pozwalają na duże zrównoleglenie obliczeń, jednak charakteryzują się znacznym zużyciem energii. Tworzenie specjalizowanych układów scalonych (ASIC ang. *application-specific integrated circuit*) daje najlepsze rezultaty w implementacji systemu wizyjnego, ale ich opracowanie i produkcja wymaga bardzo dużych nakładów finansowych. Dobre rozwiązanie stanowią układy rekonfigurowalne, które charakteryzują się podobnymi możliwościami w realizacji wyspecjalizowanych zadań co układy ASIC, ale nie wymagają dużych nakładów finansowych w ich tworzeniu.

Układy FPGA (ang. *Field-Programmable Gate Array*) umożliwiają zrównoleglenie obliczeń i są szeroko stosowane w systemach wizyjnych. Szczególnie chętnie są wykorzystywane do realizacji operacji niskiego poziomu, przygotowując wstępnie obraz do dalszej analizy na wysokim poziomie. Przykłady takich operacji to: filtry konwolucyjne, filtry 2D, podpróbkowanie, wykrywanie krawędzi, obliczanie SAD (ang. *sum of absolute differences*) z regionu zainteresowania, obliczanie orientacji krawędzi i histogramów, obliczanie strumieniowo statystyk (wartość maksymalna, minimalna, średnia), zmiana przestrzeni barw [**kisacanin2008embedded**]. Dodatkową zaletą układów FPGA jest mały pobór mocy, co czyni je niezwykle atrakcyjne dla aplikacji mobilnych – takich jak drony czy czujniki środowiskowe [5]. Układy heterogeniczne łączą w jednej obudowie dwa układy o różanej architekturze i funkcjonalności. Przykładem takiego połączenia jest Zynq-7000 firmy Xilinx, który integruje w sobie układ FPGA oraz procesor ARM. Największą zaletą takiego rozwiązania jest wysoka przepustowość transferu danych między procesorem a logiką programowaną.

Niniejsza praca stanowi kontynuację i rozwinięcie pracy inżynierskiej autora.

## 1.1. Cel pracy

Celem pracy była realizacja wbudowanego systemu wizyjnego do detekcji wybranych obiektów (np. ludzi) na podstawie obrazu z kamery termowizyjnej. Zakłada się, że jako platforma obliczeniowa zostanie użyty układ heterogeniczny (np. Zynq firmy Xilinx), który umożliwia implementację sprzętowo-programową algorytmów. W pierwszym etapie pracy należało dokonać przeglądu i oceny zrealizowanego w ramach pracy inżynierskiej algorytmu, a także

przeprowadzić pogłębioną analizę literatury związanej z tematem. Należało zwrócić szczególną uwagę na systemy detekcji pieszych (wspomaganie kierowcy) oraz systemy dla autonomicznych pojazdów latających (dronów). Warto także rozważyć możliwość wykorzystania kontekstu czasowego tj. informacji zawartej w sekwencji obrazów. Na tej podstawie należy wytypować algorytmy, które zostaną zaimplementowane i przetestowane w aplikacji programowej (Matlab/C++/Python/OpenCV). Należało również zgromadzić bazę zdjęć lub sekwencji testowych.

W drugim etapie należało wybrane wspólnie z opiekunem pracy algorytmy zaimplementować w systemie programowo sprzętowym, uruchomić oraz sprawdzić ich skuteczność w różnych scenariuszach testowych.

Oczekiwanym rezultatem pracy był: opis wykorzystania informacji termowizyjnej w detekcji pieszych (systemy wspomagania kierowcy) oraz detekcji ludzi z wykorzystaniem dronów, implementacja i analiza kilku podejść (w aplikacji programowej), implementacja sprzętowo-programowo wybranych algorytmów detekcji.

## 1.2. Struktura pracy

Pracę rozpoczyna wstęp w którym przedstawiono możliwości i zastosowania kamer termowizyjnych. Wskazano również zalety wykorzystania poczerwieni do rozszerzenia spektrum konwencjonalnej kamery wizyjnej – analizy multispektralnej. W rozdziale 2 zostały omówione sposoby uzyskania obrazu multisektralnego. Rodziła rozpoczyna się od scharakteryzowania promieniowania podczerwonego oraz metody jego rejestracji. Następnie został zaprezentowany model kamery otworkowej oraz transformacja projekcyjna, które stanowią podstawę teoretyczną do prawidłowego połączenia obrazów z dwóch różnych kamer. W rozdziale ?? przedstawiono ogólny zarys algorytmów służących do detekcji pieszych. W poszczególnych sekcjach zostały omówione poszczególne etapy przetwarzania obrazu i klasyfikacji wraz z ogólnie stosowanymi rozwiązaniami. Następnie w rozdziale 4 zostały omówione sposoby zrównoleglenia obliczeń i możliwość FPGA na przykładzie układu heterogenicznego Zynq-7000 firmy Xilinx. Kolejny rozdział 5 zawiera streszczenia kilku wybranych artykułów które poruszają tematykę związaną z niniejszą pracą. W rozdziale ?? przedstawiono koncepcję zaproponowanego rozwiązania wraz z szczegółami dotyczącymi jego wykonania. Całość zakończono podsumowaniem.



## 2. System multispektralny

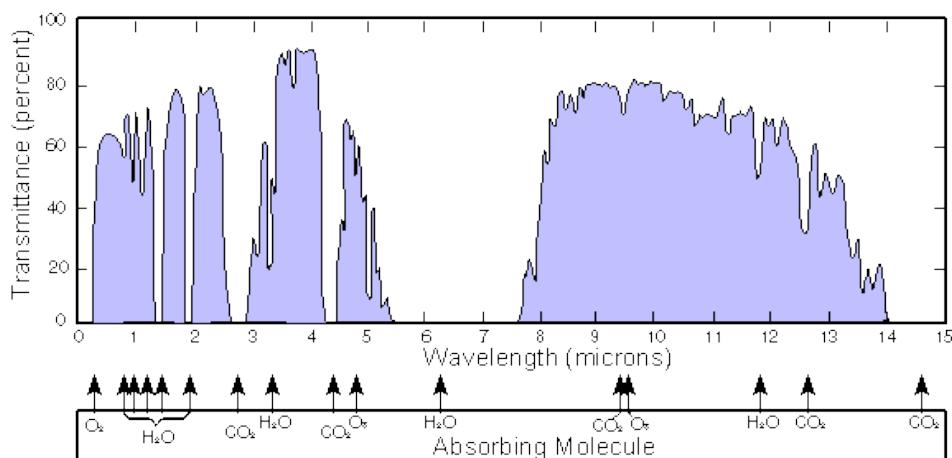
### 2.1. Podczerwień

Każde ciało, które ma temperaturę wyższą niż zero absolutne emisję swoja powierzchnią promieniowanie, którego natężenie zwiększa się wraz z jej wzrostem. Dla każdej temperatury danego ciała istnieje charakterystyczna długość fali o najwyższej wartości mocy promieniowania. Wraz z wzrostem temperatury ta częstotliwość przesuwa się w zakres fal widzialnych. Można to zaobserwować, gdy stal osiąga wysoką temperaturę co skutkuje emisją światła. Zależność ta jest opisana prawem Plancka, które opisuje emisję promieniowania elektromagnetycznego przez ciało doskonale czarne. Ciało doskonale czarne to wyidealizowane ciało fizyczne, które całkowicie pochłania padające na nie promieniowanie oraz emituje promieniowanie ściśle związane z jego temperaturą. Wykres na rysunku 2.1 przedstawia tą zależność.

Mianem podczerwieni określa się promieniowanie elektromagnetyczne w zakresie fal o długości od  $0,75 \mu m$  do  $1000 \mu m$ . Wyróżnia się następujące pasma podczerwieni:

- Bliska podczerwień (NIR ang. *near infrared*) w zakresie  $0,75 \mu m$  do  $1,4 \mu m$ .
- Podczerwień fal krótkich (SWIR ang. *short-wavelength infrared*) w zakresie  $1,4 \mu m$  do  $3 \mu m$ .
- Podczerwień fal średnich (SWIR ang. *mid-wavelength infrared*) w zakresie  $3 \mu m$  do  $8 \mu m$ .
- Podczerwień fal długich (LWIR ang. *long-wavelength infrared*) w zakresie  $8 \mu m$  do  $15 \mu m$ .
- Daleka podczerwień (FIR ang. *long-wavelength infrared*) w zakresie  $15 \mu m$  do  $1000 \mu m$ .

Bliska podczerwień znajduje się tuż za zakresem światła widzialnego ludzkiem wzrokiem i jest możliwa do rejestracji przez typowe dla kamer sensory CCD czy CMOS (często z zastosowaniem oświetlaczy IR). Wraz z wzmacniaczem światła jest również stosowana w noktowizji.



Rys. 2.1. Wykres transmisyjności atmosfery dla promieniowania podczerwonego [7].

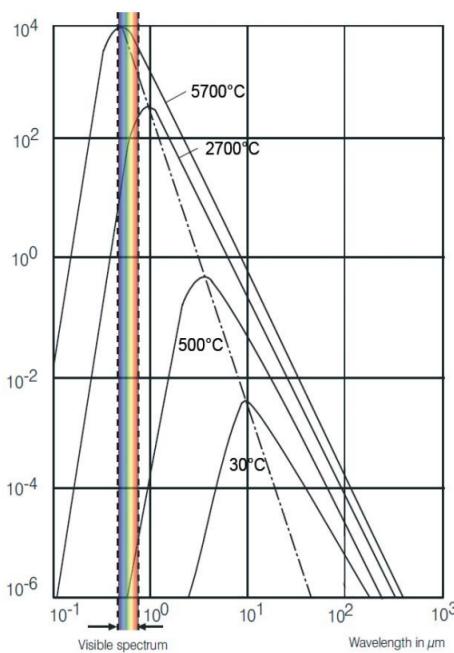
SWIR i LWIR występują także pod nazwą termowizji. Promieniowanie podczerwone jest częściowo pochłaniane przez atmosferę ziemską. Na rysunku 2.2 przedstawiono tzw. transmisję atmosfery. W aparaturze rejestrującej w podczerwieni wykorzystuję się dwa zakresy przy których transmisjność jest największa: 3 – 5  $\mu\text{m}$  oraz 8 – 14  $\mu\text{m}$  [6].

## 2.2. Kamera termowizyjna

### 2.2.1. Sensor podczerwieni

W kamerach do rejestracji obrazu w termowizji są wykorzystywane sensory FPA (ang. *Focal Plane Array* - płaskie zespoły ogniskujące). Najbardziej popularne typy to : InSb, InGaAs, HgCdTe (w postaci fotodiod; wymagają kriogenicznych warunków pracy) and QWIP (ang. *Quantum well infrared photodetector*). Najnowsze technologie wykorzystują niskobudżetowe, niewymagające chłodzenia mikrobolometry.

Firma Flir wykorzystuje tlenek wanadu do budowy mikrobolometrów m.in. w kamerach Lepton. Tlenek walandu cechuje się dużym temperaturowym współczynnikiem rezystancji (TWR) oraz małym szumem 1/f co zapewnia doskonałą wrażliwością oraz stabilną jednolitość. Do uzyskania obrazu zespół soczewek skupia promieniowanie z rejestrowanej sceny na macierz detektorów. W każdym z detektorów w odpowiedzi na padającą na niego wiązkę promieniowania, zmienia się temperaturę zawartego w nim tlenku wanadu. Zmiana temperatury wiąże się proporcjonalnie ze zmianą rezystancji. Rejestracja sceny polega na odczycie rezystancji każdego detektora poprzez przyłożenia napięcia i odczyt przepływającego przez nie prądu [8].



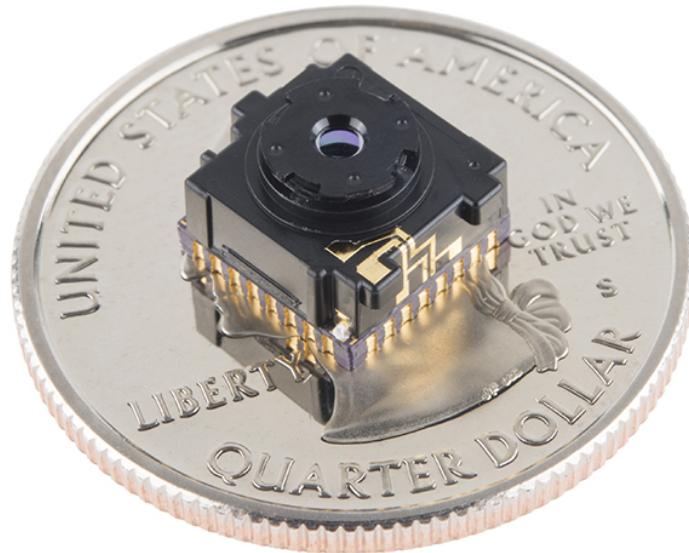
Rys. 2.2. Emisyjność ciała idealnie czarnego.

### 2.2.2. Kamera termowizyjna FLIR Lepton

Lepton jest miniaturową kamerą termowizyjną. W pojedynczym układzie został zintegrowany kompletny system składający się soczewki, sensora podczerwieni fal długich (ang. LWIR – *long wave infrared*) oraz elektroniki sterującej i przetwarzającej sygnał. Cechuje się bardzo małymi wymiarami, co czyni ją idealnym do zastosowań mobilnych. Układ ma możliwość domontowania dodatkowej przesłony, która jest wykorzystywana do automatycznej optymalizacji procesu ujednolicania obrazu (kalibracji sensora). Układ jest prosty do integracji z dowolnym mikrokontrolerem dzięki zastosowaniu standardowych protokołów i interfejsów. Lepton po podłączeniu zasilania od razu uruchamia się w domyślnym trybie pracy. Kamera jest konfigurowalna poprzez CCI (ang. *camera control interface* – interfejs kontroli kamery), poprzez który jest dostęp do rejestrów zawierających konfigurację [lepton].

Parametry kamery:

- Wymiary: 11,8 x 12,7 x 7,2 mm,
- Sensor: niechłodzony mikrobolometr VOx (tlenek wanadu),
- Rejestrowany zakres: fale długie podczerwieni,  $8\mu m$  do  $14\mu m$ ,
- Wielkość piksela:  $17 \mu m$ ,
- Rozdzielcość: 80x60 pikseli,

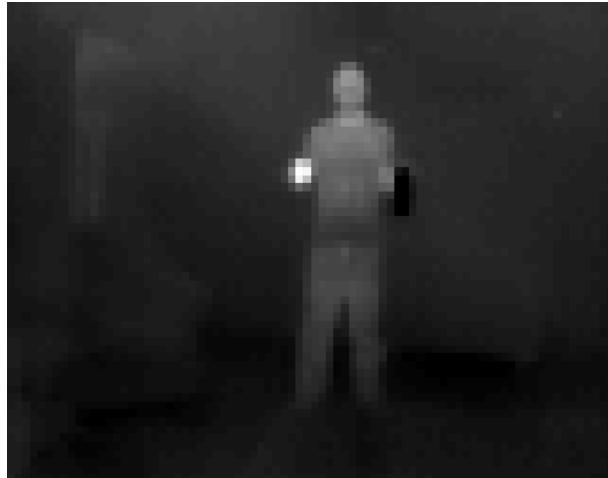


Rys. 2.3. Widok poglądowy na kamerę FLIR Lepton.

- Liczba klatek na sekundę: 8,6,
- Zakres rejestrowanych temperatur:  $-10^{\circ}\text{C}$   $140^{\circ}\text{C}$  (tryb wysokiego wzmacnienia),
- Korekta niejednorodności matrycy: automatyczna na bazie przepływu optycznego,
- Kąt widzenia horyzontalny / diagonalny:  $51^{\circ}$   $66^{\circ}$ ,
- Głębia ostrości: od 10cm do nieskończoności,
- Format wyjściowy: do wyboru: 14-bit, 8-bit (z AGC (ang. *automatic gain control* – automatyczna kontrola wzmacnienia)) 24-bit RGB (z ACG i koloryzacją),
- Interfejs wideo: VoSPI (Video over Serial Peripheral Interface),
- Interfejs sterujący: CCI (zbliżony do I2C).

## 2.3. Rejestracja obrazu multispektralnego

Widmo elektromagnetyczne docierające do kamery składa się fal o różnych długościach. Sensory w kamerach rejestrują obraz tylko w pewnym zakresie tego widma, więc aby uzyskać




Rys. 2.4. Onbraz człowieka w termowizji wykonany kamerą Lepton. W prawej ręce widać gorący obiekt (harbatę), w lewej zimny (butelka wody z lodówką).

obraz w wymaganym paśmie należy odfiltrować niepożądane elementy widma, np. kolorowy obraz z kamery wizyjnej jest otrzymywany poprzez zastosowanie trzech filtrów: czerwonego, zielonego i niebieskiego. Ponieważ wszystkie trzy kolory mogą być zarejestrowane przez pojedynczą matrycę, filtry są nałożone bezpośrednio na sensor a wartość koloru w danym punkcie jest interpolowana z sąsiadujących ze sobą pikseli. W przypadku, gdy nie jest możliwe zastosowanie jednego sensora do wszystkich pożądanych zakresów należy rozdzielić wiązkę pomiędzy różne aparaty, albo wykorzystać równoległy układ kamer.

W przypadku rejestracji obrazu wizyjnego i termicznego większość implementacji wykorzystuje układ dwóch równoległych do siebie kamer, której przykład przedstawia rysunek 2.5a. W tym przypadku została zastosowana kamera termowizyjna Flir Tao 2 oraz kamery wizyjnej logitech webcam c600. Zazwyczaj obrazy z kamer różnią się, co wynika z ich budowy, różnej rozdzielczości, kąta widzenia jak oraz zniekształceń soczewkowych. Do poprawnego odwzorowania tej samej sceny w obu widmach należy zastosować algorytm mający na celu dopasowanie obu obrazów. Tworzony jest w ten sposób nowy obraz, na którym wszystkie piksele łączą informacje o kolorze i temperaturze.

Pierwszym z etapów poprawnego dopasowania obrazów jest kalibracja. Wykonuje się ją z wykorzystaniem specjalnych plansz, które pozwalają określić położenie pewnych punktów w przestrzeni w obu rejestrowanych zakresach promieniowania. Punkty te pozwalają na obliczenie relacji między obrazami. Plansze mogą być aktywne (posiadają własne źródło ciepła) albo pasywne (przesłaniają obce źródło ciepła). W równoległym układzie kamer występuje również zjawisko paralaksy, które powiększa się wraz z wzrostem odległości obiektu od punktu kalibracji.

W pracy [4] autorzy zastosowali zwierciadło półprzezroczyste wykonane z wafla krzemowego pokrytego cynkiem do rozdzielenia obrazu wizyjnego od termicznego (rysunek 2.5b). Wykorzystując trójosiowy uchwyt, kamery zostały ustawione tak, by ich osie optyczne pokrywały się. Następnie obrazy z obu kamer zostały zrektyfikowane aby miały tą samą wirtualną ogniskową.

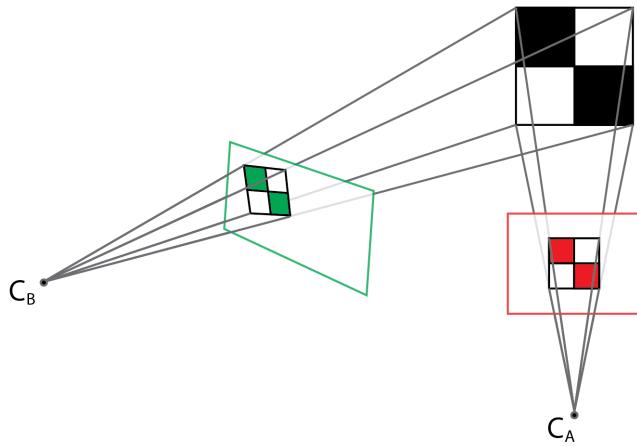


**Rys. 2.5.** Sposoby akwizycji obrazów: (a) dwie kamery równolegle [2], (b) z wykorzystaniem zwierciadła półprzezroczystego [4].

### 2.3.1. Model geometryczny

Do opisu matematycznego systemu wykorzystuje się model kamery otworkowej. Dzięki niemu można opisać relację między trójwymiarową przestrzenią a dwuwymiarowym obrazem za pomocą projekcji perspektywicznej. Nie stanowi on najdokładniejszego opisu matematycznego kamery, nie ma w nim uwzględnionych zakłóceń soczewkowych, jednakże zapewnia dobre rezultaty w wielu aplikacjach. Model składa się z 2 zestawów parametrów: zewnętrznych oraz wewnętrznych. Parametry zewnętrzne definiują lokację kamery względem zewnętrznego układu współrzędnych. Są reprezentowane przez wektor translacji  $T$  między układem związanym z kamerą  $(X_c, Y_c, Z_c)$  a zewnętrznym  $(X, Y, Z)$ . Drugim parametrem jest macierz rotacji  $R$  (między osiami tych dwóch układów). Punkt  $P = [X, Y, Z]^T$  będący w zewnętrznym układzie współrzędnym ma swój odpowiednik w układzie wewnętrznym, który można określić zależnością

$$P_c = RP + T \quad (2.1)$$



**Rys. 2.6.** Dwie kamery rejestrujące jeden obiekt.

Właściwości optyczne kamery można przedstawić w postaci macierzy kamery.

$$K = \begin{bmatrix} f_x & 0 & x_0 \\ 0 & f_y & y_0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.2)$$

gdzie:

$f_x, f_y$  = ogniskowa kamery wyrażona w liczbie pikseli,  
 $x_0, y_0$  = współrzędne punktu głównego.

Macierz  $K$  określa związek między znormalizowanymi współrzędnymi w układzie odniesienia kamery danych wzorem  $x_n = \frac{X_c}{Z_c}$ ,  $y_n = \frac{Y_c}{Z_c}$  a odpowiadającym im współrzędnymi punktów na obrazie  $u, v$ :

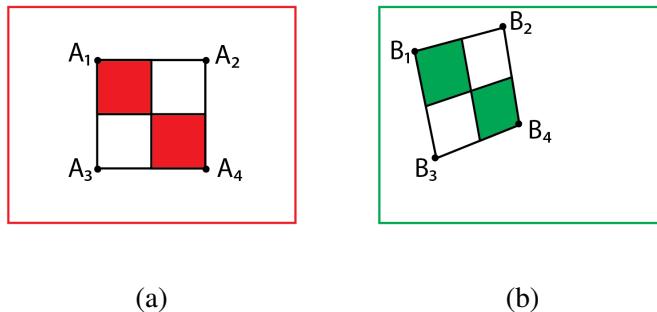
$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \begin{bmatrix} x_n \\ y_n \\ 1 \end{bmatrix} \quad (2.3)$$

### 2.3.2. Kalibracja

Obrazy które przedstawiają tę samą scenę ale zostały wykonane dwoma różnymi kamerami w innych położeniach, różnią się. Na rysunku 2.6 czarna szachownica jest uchwycona przez dwie kamery ustalone w punktach  $C_A$  (na wprost obiektu) oraz  $C_B$  (po skosie i lekko obrócona).

Aby dopasować te dwa obrazy, tak by szachownice były ujęte tak samo, należy na jednym z nich przeprowadzić transformację projekcyjną. Jest to przekształcenie pomiędzy dwoma płaszczyznami.

czyznami, które wykorzystuje model geometryczny kamery. Wymaga to obliczenia macierzy transformacji  $A$  na podstawie co najmniej 4 punktów kalibracyjnych.



**Rys. 2.7.** Zarejestrowane obrazy: (a) przez kamerę  $C_A$ , (b) przez kamerę  $C_B$ .

Punkty  $A$  i  $B$  są punktami kalibracyjnymi.

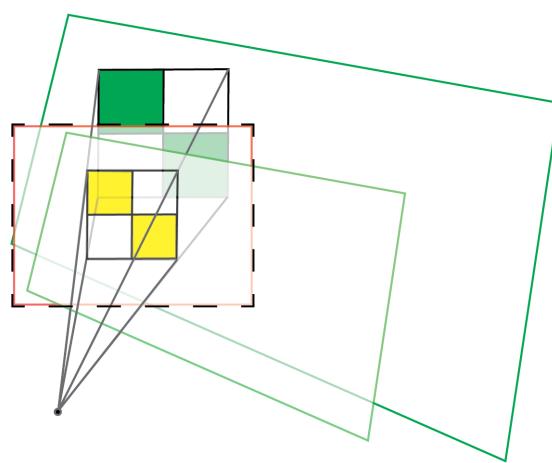
Na rysunkach 2.7a i 2.7b punkty  $A_1$  do  $A_4$ , będące czterema rogami zarejestrowanej szachownicy przez kamerę  $C_A$ , odpowiadają punktom  $B_1$  do  $B_4$  będącymi tymi samymi czterema rogami zarejestrowanymi kamerą  $C_B$ . Macierz transformacji  $A$  można obliczyć rozwiązując równanie (2.4).

$$A = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & 1 \end{bmatrix} \quad (2.4)$$


$$\begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \\ \dots \\ u_n \end{bmatrix} = \begin{bmatrix} x_1 & y_1 & 1 & 0 & 0 & 0 & -u_1x_1 & -u_1y_1 \\ x_2 & y_2 & 1 & 0 & 0 & 0 & -u_2x_2 & -u_2y_2 \\ x_3 & y_3 & 1 & 0 & 0 & 0 & -u_3x_3 & -u_3y_3 \\ x_4 & y_4 & 1 & 0 & 0 & 0 & -u_4x_4 & -u_4y_4 \\ \dots \\ x_n & y_n & 1 & 0 & 0 & 0 & -u_nx_n & -u_ny_n \\ 0 & 0 & 0 & x_1 & y_1 & 1 & -v_1x_1 & -v_1y_1 \\ 0 & 0 & 0 & x_2 & y_2 & 1 & -v_2x_2 & -v_2y_2 \\ 0 & 0 & 0 & x_3 & y_3 & 1 & -v_3x_3 & -v_3y_3 \\ 0 & 0 & 0 & x_4 & y_4 & 1 & -v_4x_4 & -v_4y_4 \\ \dots \\ 0 & 0 & 0 & x_n & y_n & 1 & -v_nx_n & -v_ny_n \end{bmatrix} \begin{bmatrix} a \\ b \\ c \\ d \\ e \\ f \\ g \\ h \end{bmatrix} \quad (2.5)$$

$u_n, v_n$  = współrzędne punktu kalibracji  $n$ , na obrazie bazowym

$x_n, y_n$  = współrzędne punktu kalibracji  $n$ , na obrazie dopasowywanym



Rys. 2.8. Interpretacja transformacji projekcyjnej: rzutowanie płaszczyzny.



Rys. 2.9. Wynik transformacji.

Transformację projekcyjną można zinterpretować jako rzutowanie płaszczyzny, co obrazuje rysunek 2.8. Wynikiem transformacji (a zarazem rzutowania) jest obraz dopasowany do obrazu bazowego (2.9)



## 3. Algorytmy detekcji pieszych

W cyfrowej analizie obrazu rozpoznawanie pieszych jest jedną z najbardziej aktywnie rozwijanych dziedzin. W przeciągu kilkudziesięciu lat powstało ponad tysiąc artykułów poruszających to zagadnienie [9], w których zaproponowano wiele różnych metod. Większość metod opiera się o analizę obrazu tylko w jednym spektrum: widzialnym albo podczerwieni. Praca [4] pokazała, iż połączenie obu obrazów może dać lepsze wyniki. Podobnie w artykule [10] wykazano, że analiza multispektralna jest skuteczniejsza w dzień niż w nocy (o około 5% AMR (ang. *avrange miss rate*)). W artykule [11] autorzy podsumowują osiągnięcia w dziedzinie detekcji pieszych w latach 2004 – 2014. Wyróżniono ponad 40 różnych podejść do problemu. Eksperymenty w artykule są oparte o bazę danych Caltech-USA, która zawiera obrazy w kolorze. Jednym z wniosków jest to, że przez ostatnie dziesięć lat największy postęp został osiągnięty głównie dzięki dopracowaniu cech, które są wyodrębniane z obrazu, niż ulepszanie klasyfikatora. Dodatkowo autorzy połączycyli cechy dające najlepsze wyniki i stworzyli własną metodę, która uzyska 12% zysk AMR względem najlepszej badanej wcześniej metody.

Dla typowego algorytmu detekcji pieszych można wyróżnić trzy podstawowe etapy:

### 3.1. Ustalenie regionu zainteresowań

Jest to obszar zwany ROI (ang. *region of interest*), w którym potencjalnie mogą znajdować się plesi. Wiele podejść uznaje cały obraz jako ROI i stosuje okno przesuwne, sprawdzając każdy możliwy fragment obrazu. Jeżeli scena jest rejestrowana przez nieruchomą kamerę, ROI można określić poprzez różnicę między zapamiętany tłem, a aktualnym obrazem (tzn. modelowanie i odejmowanie tła). Analiza przepływu optycznego również pozwala na wyodrębnienie obszaru, który swoim ruchem różni się od reszty. Inną metodą jest zastosowanie słabszego, bardziej ogólnego klasyfikatora ale mniej wymagającego obliczeniowo. Wyodrębnienie ROI jest bardzo istotne w przypadku pracy w czasie rzeczywistym, ze względu na ograniczony czas analizy pojedynczego obrazu.

## 3.2. Wyodrębnienie cech

Do najbardziej popularnych cech można zaliczyć:

1. Histogramy zorientowanych gradientów (HOG ang. *Histogram of Oriented Gradients*). Algorytm został zaproponowany przez N.Dalala i B. Triggs w pracy [12] i stał się jednym z najbardziej popularnych technik w dziedzinie detekcji ludzi. Jest cały czas rozwijany i modyfikowany w wielu pracach naukowych. Technika polega na zliczeniu kierunków gradientów, uzyskanych z 2 masek kierunkowych  $\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$  i  $\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}^T$ , w komórkach o określonych wymiarach. Komórki te są organizowane w bloki, w obrębie których następuje normalizacja. Wektorem cech jest połączeniem wszystkich histogramów z wszystkich bloków.
2. Lokalne wzorce binarne LBP (ang. *Local Binary Patterns*). Oryginalnie deskryptory te zaproponowane zostały do opisu tekstur. Analizowany obraz zostaje podzielony na bloki. Następnie, do każdego piksela w bloku zostaje przypisany wzorzec binarny na podstawie wartości pikseli w jego sąsiedztwie. Jeżeli wartość sąsiadującego piksela jest większa od centralnego to przyjmuje on wartość 1. W ten sposób do każdego piksela przypisywany jest wzorzec binarny (np. 100110). Następnie zostaje obliczony histogram dla każdego bloku. Histogramy z wszystkich bloków wchodzących w skład obrazu tworzą wektor cech [13].
3. Falki Haara. Określają różnicę w kontraste między dwoma przylegającymi prostokątnymi obszarami. W oryginalnej pracy P.Viola i M.Jones z 2001 [14] autorzy rozważali 3 rodzaje cech: Dwa obszary mające ten sam rozmiar i kształt oraz przylegające do siebie horyzontalnie bądź wertykalnie, gdzie cechę stanowi różnica sumy pikseli zawartych w każdym z regionów. Obszar składający się z 3 prostokątów przylegających do siebie gdzie od sumy środkowego elementu jest odejmowana suma dwóch zewnętrznych oraz układ 4 prostokątów, gdzie suma jest różnicą między obszarami po przekątnej. Cechy są łatwe do skalowania i nie wymagają dużych nakładów obliczeniowych.
4. Kolor. W analizie obrazów wykorzystuje różne przestrzenie barw np. RGB, HSV oraz LUV. Wykorzystywane głównie gdy kolor wykrywanego obiektu jest kluczowy(np. znaki drogowe, światła na skrzyżowniu). Jako cecha można go wykorzystać w kilku formach. Momenty koloru (ang. *Color Moments*) jest to średnia, wariancja i odchylenie standarde występowania danego koloru w obrazie. Histogram określa częstość występowania danego koloru na obrazie. Wektor koherencji koloru (CCV ang. *Color Coherence Vectors*) określa w jakim stopniu piksele danego koloru są częścią obszaru o podobnym

kolorze (np. obraz zielonej łąki na którym pasie się jedna fioletowa krowa. Kolor zielony na obrazie byłby rozłożony równomiernie natomiast fioletowy byłby skupiony w pojedynczym rejonie koherencji - krowy) [15].

### 3.3. Klasyfikator

Otrzymany wektor cech jest poddany klasyfikacji, której wynik decyduje czy obraz zawiera człowieka. W pracy [11] autorzy wyróżnili 3 dominujące rodziny metod:

1. Rodzina DPM (ang. *Deformable Part Model*)

Technika zakłada że obiekty mogą być zamodelowane poprzez części ułożone w deformowanych konfiguracjach. Model składa się z głównego, globalnego filtra, który stanowi punkt odniesienia dla pozostałych części. Każda część zawiera swój własny filtr wraz z zestawem dozwolonych pozycji względem okna detekcyjnego, oraz koszt deformacji dla każdej z tych pozycji. Suma wyniku uzyskanego z filtra głównego wraz z jego częściami stanowi o wyniku detekcji [16].

2. Deep networks. Głębokie sieci neuronowe posiadają kilkanaście warstw ukrytych między warstwą wejściową i wyjściową. Jej działanie polega na tym że po podaniu wektora cech na warstwę wejściową wytrenowanej sieci, w warstwie wyjściowej aktywuje się neutron odpowiedzialny za daną klasę. W analizie obrazu szczególnie chętnie są wykorzystywane sieci konwolucyjne. Neurony pierwszej warstwy ukrytej są podłączone jedynie do wybranego fragmentu warstwy wejściowej (np. okna 5x5 obrazu albo pojedynczego histogramu w komórce). Jest to tzw. warstwa konwolucyjna. Neurony w tej warstwie dzielą wspólne wagi dla swoich wejść i bias. Sieć posiada zazwyczaj kilkanaście takich warstw każda wykrywająca pojedynczą cechę. Pozwala to na redukcję ilości potrzebnych neutronów i mniejszą ilość parametrów potrzebnych do uzyskania w procesie uczenia. Do warstw konwolucyjnych dochodzą warstwy sumujące (ang. *pooling layers*). Zadaniem warstwy jest generalizacja informacji z poprzedniej warstwy. Sieć zamyka w pełni połączona z poprzednimi, warstwa wyjściowa.

3. Decision forests – lasy decyzyjne zbiór nieskorelowanych drzew decyzyjnych. Drzewo jest graficznym odwzorowaniem procesu decyzyjnego. Algorytm uczenia drzew wykorzystuje przykłady (wektor cech) i związane z nimi konsekwencje (klasyfikacja obiektu) [\[wikiedia\]](#).

4. inne: np. SVM (ang. support vector machine – maszyna wektorów nośnych), AdaBoost itp.



## 4. Wykorzystanie FPGA w analizie obrazu

Tradycyjne systemy wizyjne zwykle bazują na architekturze sekwencyjnej. W tym rozwią- zaniu obraz jest sukcesywnie poddawany kolejnym przekształceniom, a wyniki pośrednie zapisywane są w pamięci operacyjnej. W aplikacji procesorowej operacje te są wykonywane przez układ arytmetyczno-logiczny. Kolejne kroki algorytmu są kompilowane w ciąg instrukcji dla procesora, który oprócz operacji matematycznych dużą część pracy poświęca na pobieranie i dekodowanie rozkazów oraz na odczytywanie i zapisywanie danych do pamięci. By taka aplikacja mogła pracować w czasie rzeczywistym, cała procedura musi wykonać się szybciej niż przychodzące dane obrazu, co wymusza wysokie taktowanie procesora sięgające kilku GHz. To podejście jednak ma swoje ograniczenia. Wraz z wzrostem częstotliwości pracy procesora wzrasta jego moc a tym samym ilość ciepła które która musi zostać rozproszone. Najszybsze CPU są taktowane z częstotliwością zegara sięgającą nawet 4,4 GHz (choć przy zastosowaniu chłodzenia ciekłym azotem jest możliwe uzyskanie ponad 8 GHz). Wzrost szybkości obliczeń uzyskuje się coraz częściej poprzez zwiększenie ilości rdzeni w procesorze.

W przypadku podejścia równoległego, implementacja poszczególnych kroków algorytmu odbywa się w osobnych procesach. Jeżeli wykonywany algorytm jest głównie sekwencyjny tzn. kolejne kroki algorytmu wymagałyby danych otrzymanych z poprzednich, to zysk takiego zabiegu byłby równy zero. W celu uzyskania dobrej implementacji w układzie równoległym, istotne jest by znaczna część algorytmu mogła być wykonywana równolegle. Maksymalne do uzyskania przyspieszenie jest określone przez prawo Amdahla:

$$P_w = \frac{1}{s + \frac{1-s}{n_w}} \quad (4.1)$$

gdzie:

$P_w$  = przyspieszenie algorytmu w systemie wieloprocesorowym,

$s$  = część algorytmu niepodlegająca zrównolegleniu (wartość od zera do jeden),

$n_w$  = liczba elementów obliczeniowych.

Algorytmy przetwarzania obrazów są w dużej mierze równoległe, szczególnie te niskiego i średniego poziomu. W wielu przypadkach każdy piksel obrazu można obliczyć niezależnie,

np. w wszelkich operacjach kontekstowych, przekształceniach przestrzeni barw, binaryzacji itp. Między innymi dlatego układy FPGA są chętnie stosowane w systemach wizyjnych. Teoretycznie jedynym ograniczaniem w możliwości zrównoleglenia obliczeń jest liczba dostępnych zasobów w układzie, jednak innym istotnym aspektem jest sposób dostarczania danych do modułów obliczeniowych.

Dostęp do pamięci często wymaga czasu a ilość danych przekazana podczas jednego transferu jest ograniczona. Stanowi to wąskie gardło w tego rodzaju rozwiązaniach.

Z tego powodu przetwarzanie obrazu bezpośrednio z sensora w czasie jego akwizycji jest chętnie wykorzystywane, gdyż zmniejsza to liczbę operacji odczytu i zapisu. [5]

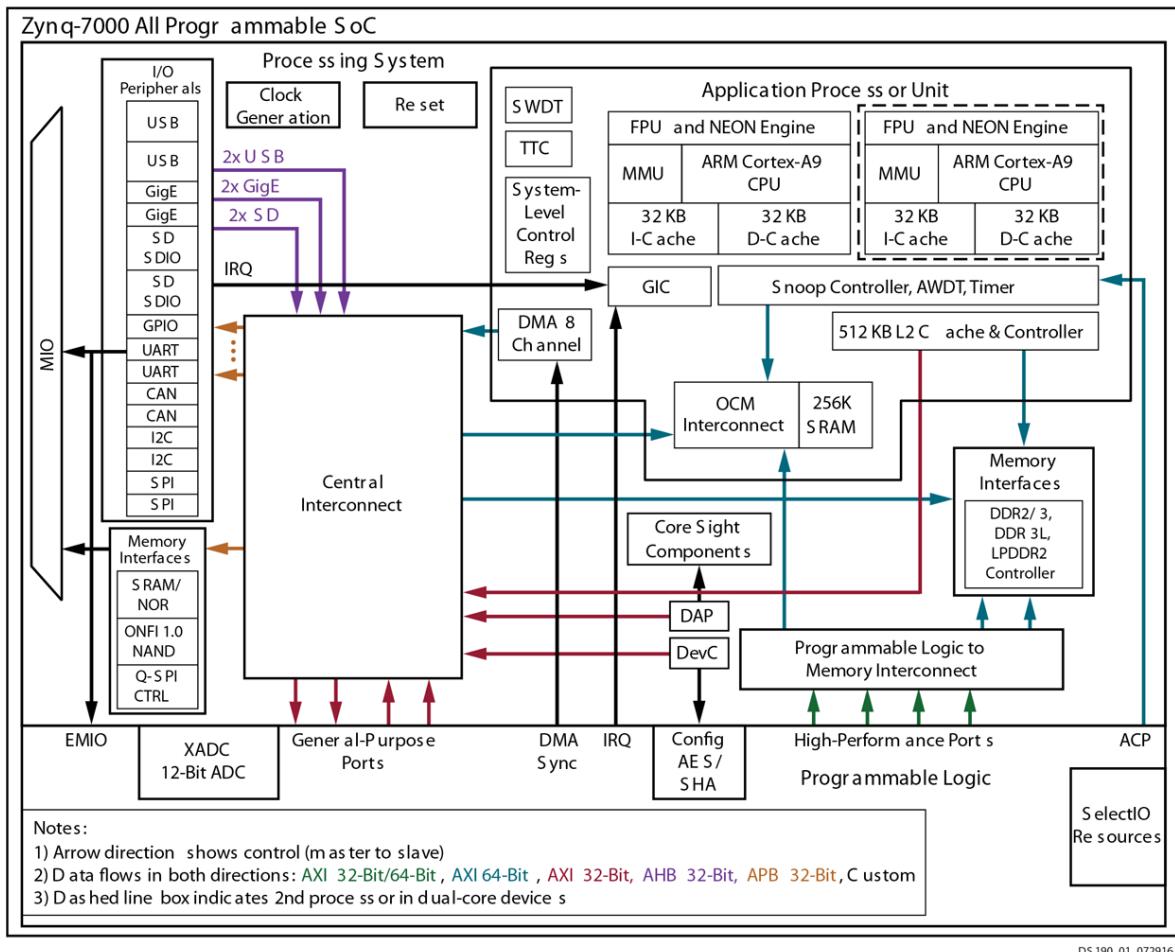
## 4.1. Zynq-7000

Rodzina układów Zynq-7000 bazuje na architekturze SoC (ang. *System on Chip*). W pojedynczym układzie scalonym został zawarty kompletny system w skład którego wchodzą układy spełniające różne funkcje. Został on podzielony na dwie główne części: systemu procesorowy (PS ang. *Porcessing System*) bazujący na procesorze ARM Cortex-A9 oraz logikę programowalną (PL ang. *Programable Logic*) - FPGA. Na rysunku 4.1 przedstawiono schemat architektury układu. Część procesorowa, oprócz samego ARM-a, posiada wbudowaną pamięć, kontroler pamięci zewnętrznej oraz szereg interfejsów dla układów peryferyjnych takich jak USB, GigE-thernet, CAN, I2C, SPI. W części logiki programowej znajdują się bloki logiki konfigurowalnej (CLB ang. *configurable logic block*), 36Kb bloki pamięci RAM, moduły DSP48, układ JTAG, układy zarządzania zegarami oraz dwa 12-bitowe przetworniki analogowo-cyfrowe.

Komunikacja między częścią procesorową, a logiką programową odbywa się za pośrednictwem interfejsu AXI (ang. *Advanced Extensible Interface*) oraz bezpośrednio wykorzystując porty ogólnego przeznaczenia, przerwania i bezpośredni dostęp do pamięci (DMA ang. *Direct Memory Access*).

## 4.2. Interfejs AXI

AXI (ang. *Advanced eXtensible Interface* – zaawansowany rozszerzalny interfejs) jest częścią ARM AMBA (ang. *Advanced Microcontroller Bus Architecture*) – otwartego standardu, będącego specyfikacją do zarządzania połączeniami między blokami funkcyjnymi w SoC. Aktualnie jest stosowana AMBA 4.0 która wprowadziła drugą wersję AXI – AXI4. Występują trzy typy interfejsów dla AXI4:



Rys. 4.1. Schemat ogólny architektury układu Zynq-7000.

- AXI4 – stosowany w wysokowydajnych transferach w przestrzeni pamięci (ang. *memory-mapped*),
- AXI4-Lite – stosowany dla prostszych operacji w przestrzeni pamięci (na przykład do komunikacji z rejestrami kontrolnymi i statusu),
- AXI4-Stream – stosowany do transmisji strumieniowych (wysokiej prędkości).

Specyfikacja interfejsu zakłada komunikację pomiędzy pojedynczym AXI *master* i pojedynczym AXI *slave*, która ma na celu wymianę informacji. Kilkanaście interfejsów AXI *master* i *slave* mogą zostać połączone między sobą za pomocą specjalnej struktury zwanej *interconnect block* (blok międzymodułowy), w której odbywa się trasowanie połączeń do poszczególnych bloków.

AXI4 i AXI4-Lite składają się z 5 różnych kanałów:

- Kanał adresu odczytu,

- Kanał adresu zapisu,
- Kanał danych odczytanych
- Kanał danych do zapisania
- Kanał potwierdzenia zapisu

Dane mogą płynąć w obie strony pomiędzy *master* a *slave* jednocześnie. Ilość danych, które można przesyłać w jednej transakcji w przypadku AXI4 wynosi 256 transferów, zaś AXI4-Lite pozwala na tylko 1 transmisję.

AXI4-Stream nie posiada pola adresowego, a dane mogą być przesyłane nieprzerwanie.

## **5. Przegląd literatury**

### **5.1. Koledzy z Poznania**

W pracy [17] autorzy opracowali algorytm pozwalający na szybką i efektywną detekcję przechodniów w czasie rzeczywistym. Termowizja pozwala na uzyskanie dobrego kontrastu między poszukiwanym przechodniem a otoczeniem. Zaproponowany system jest dedykowany do pracy w nocy, kiedy kontrast między człowiekiem a otoczeniem pozwala na jednoznaczne ich rozróżnienie. Rozwiążanie bazuje na ulepszonym algorytmie progowania i segmentacji obrazu.

Pierwszym etapem jest wyodrębnienie obszarów zainteresowań (ROI). Pozwala to na znaczne ograniczenie obszaru analizowanych fragmentów obrazu.

Obraz w odcieniach szarości zostaje poddany binaryzacji z użyciem dwóch progów: mniejszym i większym. Pozwala to na detekcję przechodniów w różnych rejonach obrazu o różnym kontraście. Progi zmieniają się wraz z dynamiką obrazu wejściowego. W obrazie termicznym człowieka często w okolicy bioder znajduje się chłodniejszy obszar który jest poniżej progu binaryzacji co skutkuje przerwę między dwoma połówkami człowieka. Aby połączyć je w jedną całość dodatkowo dla każdego obszaru wyłonionego podczas binaryzacji zostają wytypowane dodatkowe ROI, które obejmuje ten obszar wraz z innymi znajdującymi się nad lub pod.

Następnym krokiem jest filtracja wyników. Ma ona na celu zredukowanie liczby obszarów przed końcową analizą. Autorzy zastosowali filtrację opierającą się na proporcji obszaru zainteresowań. Pozytywnie zakwalifikowane zostały tylko obszary o odpowiednich proporcjach wysokości do szerokości (1:1.3 do 1:4). Z racji, że badany obraz pochodzi z kamery zamontowanej na stałe na samochodzie, autorzy wykorzystali filtrację perspektywiczną która uwzględnia możliwą wysokość ROI w różnych fragmentach obrazu. Filtracja jednorodnych regionów pozwoliła na odrzucenie kandydatów będących częścią szerszych obiektów nie mających nic wspólnego z przechodnimi. Obraz człowieka cechuje się dużą rozpiętością wartości temperatur. Obliczając odchylenie standardowe ROI w odcieniach szarości można wyeliminować obszary które są poniżej progu określonego przez autorów.

Ostatnim krokiem algorytmu jest klasyfikacja wytypowanych kandydatów. Autorzy wykorzystują histogram zorientowanych gradientów jako deskryptor tworząc wektor 3780 cech, które są następnie klasyfikowane przez SVM.

W celu zbadania dokładności algorytmu został przeprowadzony test na zbiorze CVC-14, który zawiera obrazy nagrane kamerą FIR podczas nocnego przejazdu samochodem. Testy wykazały, że metoda podwójnego progowania daje trzy razy lepsze rezultaty, niż przy wykorzystaniu pojedynczego progu. Wraz z zaproponowanymi technikami filtracji zaowocowało to bardzo efektywnym mechanizmem segmentacji. Ponad 95% występujących przechodniów zostało poprawnie wytypowanych jako kandydaci do klasyfikacji. Cała procedura detekcji przechodniów osiągnęła wysoki poziom wydajności na poziomie 33 klatek (o wymiarach 640x471 px) na sekundę przy wykorzystaniu pojedynczego rdzenia CPU. Dokładność detekcji wyniosła 37,3% AMR (ang. *average miss rate*), co jest porównywalna do innych metod opartych o HOG+SVM.

## 5.2. Stereotermowizja

W pracy [18] autorzy zaproponowali wykorzystanie dwóch kamer termowizyjnych tworząc system stereowizyjny. W obrazie termowizyjnym człowieka najczęściej obszarem jest zazwyczaj głowa. By wyodrębnić obszary zainteresowania, w których potencjalnie znajdują się przechodnie, zgrupowano piksele o wartościach powyżej kilku różnych progów. Każdy z tych obszarów zostaje następnie uznany za głowę i stanowi górną część okna detekcyjnego. Wielkość okna jest estymowana na podstawie odległości źródła ciepła od kamery. Odległość jest ustalana na podstawie mapy dysparcji (ang. *disparity map*). Do obliczani dysparcji okna, porównywana różnica między oryginalnym oknem a oknem przesuwnym w drugim obrazie. Dysparcja jest uzyskiwana gdy ta różnica jest minimalna. Na koniec każde okno zostaje przeskalowane do wielkości 128x64 i poddane klasyfikacji.

W tej pracy autorzy skupili się na optymalnym doborze parametrów deskryptora HOG. Zestaw zawierał 4400 obrazów: 2200 próbek z pieszymi oraz 2200 bez pieszych. Został wykorzystany następujący zestaw parametrów HOG:

Autorzy przeprowadzili po 10 procedur uczenia klasyfikatora dla każdej kombinacji wykorzystując różne kombinacje danych do nauki i testów. W tabeli 5.1 zaprezentowane są wyniki badań.

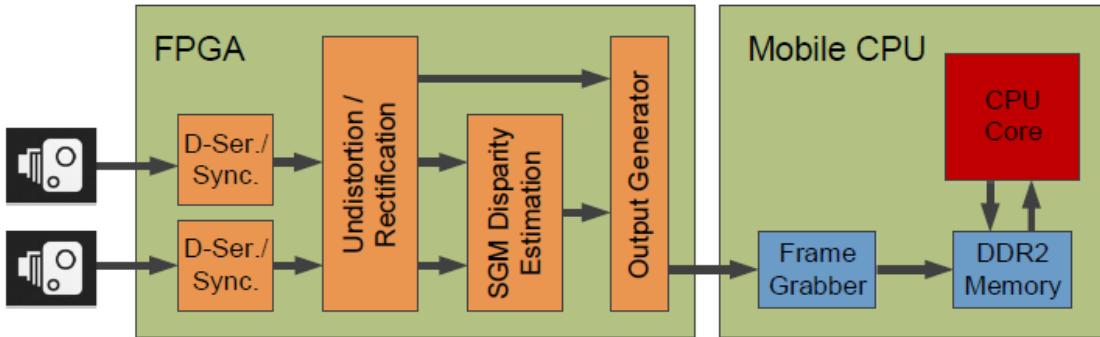
Badanie parametrów dla klasyfikacji SVM wykazało, że im większy zestaw uczący tym lepszą można uzyskać skuteczność detekcji.

**Tabela 5.1.** Parametry HoG.

Parametr	Zestaw do testów	Najlepszy wynik
Rozmiar komórki	4x4, 8x8, 16x16	8x8
Rozmiar bloku	1x1, 2x2, 4x4	2x2
Nakładanie się komórek między blokami	1,2	1
Schemat normalizacji bloków	brak, L1, L2	L2
Liczba przedziałów histogramu	4, 8, 16	8
Rodzaj histogramu	ważony, nie ważony	ważony

### 5.3. Podejście sprzętowo-programowe. Stereowizja dla robotów

W pracy [19] autorzy wykorzystali układ FPGA oraz CPU małej mocy do skonstruowania systemu wizyjnego dla robotów. System analizował obraz stereoskopowy z dwóch kamer wizyjnych tworząc mapę głębi. Obie kamery zostały bezpośrednio podpięte do układu FPGA za

**Rys. 5.1.** Schemat systemu wizyjnego zaproponowanego w pracy[19].

pomocą interfejsu LVDS (ang. *low-voltage differential signal* – niskonapięciowy sygnał różnicowy), w którym obrazy były następnie przetwarzane.

Schemat systemu jest przedstawiony na rysunku 5.1. W pierwszej kolejności obrazy z kamer są synchronizowane z wykorzystaniem bufora opóźniającego jedną linię danych. Korekcja zniekształceń soczewkowych oraz rektyfikacja zostały połączone w jedną operację. Przychodzące zsynchronizowane piksel są zapisywane do bufora. Po obliczaniu współrzędnych piksela, uwzględniającym korektę, jego wartość jest pobrana z właściwej lokalizacji w buforze wejściowym. Kolejnym krokiem było obliczanie dysparcji. W tym celu kontekst piksela z lewego

obrazu jest porównywany z okolicznymi kontekstami pikseli w prawym obrazie. Kandydat jest wyłaniany na podstawie lokalnej funkcji kosztu i stałych globalnych bazujących na algorytmie SGM (ang. *Semi-Global Matching*).

Następnie dwa oryginalne obrazy oraz mapa głębi są przesyłane do CPU za pomocą specjalnej magistrali. Moduł *frame grabbera* przechwytywał ten obraz i wykorzystując DMA (ang. *Direct Memory Acces*) zapisywał do pamięci systemu. System pracował w rozdzielczości 752x480 pikseli i 60 klatkach na sekundę. Całość, włącznie z kamerami, układem FPGA, CPU oraz konwerterami napięcia pobierała mniej niż 5W mocy. Całkowita latencja podana przez autorów rozwiązania wynosi około 2ms.

## 5.4. Podejście sprzętowo-programowe. System wspomagania kierowcy

W pracy [20] autorzy wykorzystali układ SoC (ang. *System on Chip*) do detekcji pieszych dla zaawansowanego systemu wspomagania kierowcy (ADAS ang. *advanced driver assistance system*). Głównym wyzwaniem było opracowanie systemu, która działa w czasie rzeczywistym, ma mały pobór mocy oraz niski koszt wykonania. Najbardziej skuteczne algorytmy wymagają znacznych zasobów obliczeniowych. Autorzy dokonali zatem relaksacji problemu poprzez zastosowanie prostszego deskryptora jakim jest LBP oraz klasyfikatora SVM. Po każdej stronie pojazdu została zamontowana inteligentną kamerę o szerokim, 180° horyzontalnym kącie widzenia by jak najlepiej monitorować przestrzeń wokół niego. W kamerach została przeprowadzona wstępna obróbka obrazu (rektryfikacja i skalowanie). Przetworzony obraz z kamer był transmitowany do „*Fusion-Box*”, gdzie odbywała się generacja kandydatów, klasyfikacja, weryfikacja oraz śledzenie. Wyniki były przesyłane do wbudowanego komputera PC. Rozwiązanie nie zostało jeszcze w pełni zaimplementowane, ale pierwsze testy dawały obiecujące rezultaty.

## 5.5. Wzorzec probabilistyczny

W pracy [21] autorzy wykorzystali układ FPGA i naiwny klasyfikator Bayesa do detekcji przechodniów w obrazie termowizyjnym. Klasyfikator zakłada, że wszystkie predyktatory są niezależne od siebie co znacznie upraszcza obliczenia. Za pomocą tego klasyfikatora można określić przynależność obrazu w badanym oknie do jednej z dwóch klas: zawierającego przechodnia albo nie zawiera (czyli tła). W tym przypadku predyktorami są poszczególne piksele. Dla każdego piksela w oknie określa się prawdopodobieństwo jego przynależności do danej klasy. Klasyfikacja sprowadza się do zależności (5.1).

$$\sum_{x,y} \ln p(w_{x,y}|P) > \sum_{x,y} \ln p(w_{x,y}|\bar{P}) \quad (5.1)$$

gdzie  $p(w_{x,y}|P)$  to prawdopodobieństwo że piksel  $w_{x,y}$  przynależy do obrazu człowieka  $p(w_i|\bar{P})$  przynależy do tła. Jeżeli nierówność jest prawdziwa wtedy okno zostaje sklasyfikowane jako zawierające przechodnia. Obrazy wykorzystane w systemie są binarne, co oznacza że  $p(w_{x,y}|P)$  przyjmuje dwie wartości, w zależności czy jest to piksel czarny czy biały. Można w ten sposób stworzyć macierz rozkładu prawdopodobieństwa (PDM ang. *probability distribution matrix*)która określa prawdopodobieństwo wystąpienia białego piksela w oknie (prawdopodobieństwo wystąpienia czarnego jest  $1 - p(w_{x,y}|P)$ ). Inną nazwą tej macierzy jest wzorzec probabilistyczny. Autorzy utworzyli PDM na podstawie 60 pozytywnych próbek.

W celu usprawnienia obliczeń w układzie FPGA macierz została przeskalowana na wartości całkowitoliczbowe w zakresie od 1 do 127. Następnie obliczono logarytm o podstawie dwa z uzyskanego wzorca i jej odwrotności (poprzez odjęcie od 128 wartości macierzy pozytywnej) i pomnożono przez 32. Utworzono tak dwie macierze: LPDW i LPDB dla białych i czarnych pikseli. (ang. *logarithmic probability matrix* – logarytmiczna macierz prawdopodobieństwa). Przyjęto, że prawdopodobieństwo przynależności piksela do tła jest stałe i wynosi 50%, co daje wartość 192 po uprzednich przekształceniach. Ostatecznie klasyfikacji dokonuje się z wzoru:

$$L_p = \sum_{x=1}^j \sum_{y=1}^k (th(x, y) * LPMW(x, y) + (1 - th(x, y)) * LPMB(x, y)) \quad (5.2)$$

$$L_b = j * k * 192 \quad (5.3)$$


$$IsPedestrian = \begin{cases} 1 & \text{gdy } L_p \geq L_b + K \\ 0 & \text{gdy } L_p < L_b + K \end{cases} \quad (5.4)$$

gdzie  $j$  i  $k$  stanowią wysokość i szerokość okna przesuwnego. Wartości  $L_p$  i  $L_b$  odnoszą się do sum prawdopodobieństw przynależności białego/czarnego piksela do obrazu człowieka.  $K$  jest parametrem którym określono minimalną wartość dla której klasyfikator daje poprawne pozytywne wyniki.

W omawianej pracy autorzy opracowali wzorce dla 3 różnych wielkości okna: 10x15, 8x12 i 6x9 pikseli. Do stworzenia wykorzystali jedynie górne połówki obrazu termicznego ludzkiej sylwetki, co miało na celu bardziej niezawodnego wzorca wobec różnych postur przechodniów.

## 5.6. Poprzednie prace

Praca inżynierska [22], oraz artykuł na jej podstawie[23], której kontynuacją jest mniejsza praca, rozwinięła koncepcję zaproponowaną w sekcji 5.5. Zastosowano 4 wzorce o wymiarach



Rys. 5.2. Wyniki symulacji przy różnych wartościach parametru K.

48x120, 32x80, 24x60, 19x48. Wzorzec został podzielony na 4 części: górną, dolną, prawą, lewą. Następnie, podobnie jak w DPM, układ tych 4 części decydował o jego klasyfikacji. Każda część tworzyła maskę wielkości całego okna. Jeżeli co najmniej 3 takie maski pokrywały się obszar ten był klasyfikowany pozytywnie. Pozwoliło to na znaczną poprawę działania algorytmu, co pokazuje wykres ROC przedstawiony na rysunku 5.2.

Poprawiło to również detekcję w różnych skalach. Poprzednio *muliscale* osiągnięto dzięki zastosowaniu kilku wzorców. Pojedyńczy wzorzec zapewniał detekcję w pewnym zakresie wysokości przechodniów. Im dalej odniesiał od swojej nominalnej wysokości tym bardziej należało zmniejszyć parametr  $K$  by w pojedynczym oknie było możliwe wykrycie mniejszych i większych sylwetek. Powodowało to również zwiększenie ilości fałszywych detekcji. Po wprowadzeniu modyfikacji każda część ma możliwość deformacji co w dynamiczny sposób pozwala na zmianę wysokości wzorca.

## **6. Proponowany system wizyjny**

### **6.1. Koncepcja systemu**

Zadaniem systemu jest detekcja osób w obrazie multispektralnym. Do uzyskania obrazu multispektralnego została wykorzystana kamera wizyjna, dająca obraz parametrach 640x480px i 50 klatek na sekundę oraz termowizyjna: Lepton – 80x60px i 8,9 klatki na sekundę. Obraz z kamery termowizyjnej (IR) jest dopasowywany do wizyjnego (RGB) za pomocą projekcji perspektywicznej. Wynikiem ich połączenia jest obraz multispektralny (RGBIR). Wybór ROI odbywa się tylko z wykorzystaniem obrazu termowizyjnego. W tym celu został wykorzystany moduł PDM (ang *Probability Density Matrix*) zaczerpnięty z pracy inżynierskiej autora [22]. Tworzy on listę kandydatów z której jest wybierany najbardziej prawdopodobny wynik. Następnie z ROI o wymiarach 80x192px są wyodrębniane deskryptory HOG oraz odbywa się klasyfikacja z wykorzystaniem SVM. Wynik detekcji jest prezentowany na ekranie, poprzez obramowanie sylwetki przechodnia. Do realizacji tego systemu została wykorzystana płytka deweloperska ZYBO firmy Digilent. Bazuje ona na omówionym wcześniej w rozdziale ?? układzie Zynq-7000. Jest to układ heterogeniczny co daje możliwość realizacji poszczególnych elementów systemu wizyjnego w logice programowalnej (PL) lub systemie procesorowym (PS) Zaproponowano następujący podział zadań: Logika programowalna :

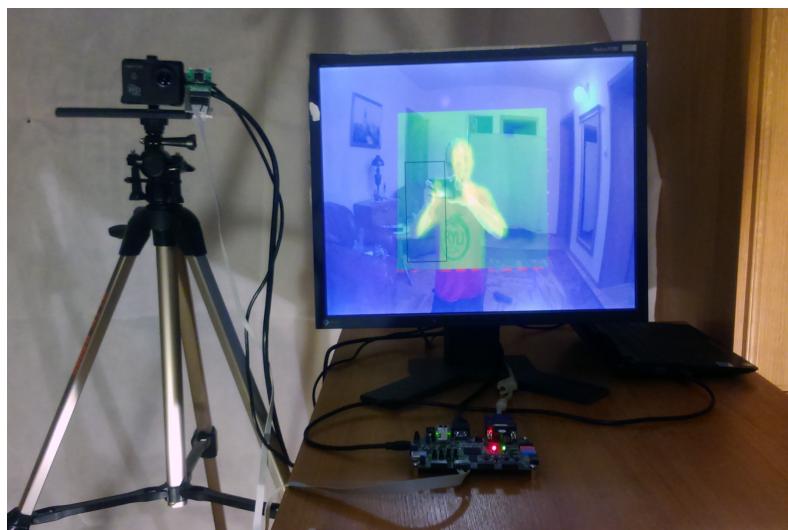
- Akwizycja obrazu poprzez HDMI (RGB) i VoSPI (IR),
- Transformata projekcyjna i interpolacja obrazu IR,
- Nałożenie i synchronizacja obrazu IR do obrazu RGB,
- Prezentacja wyników,
- Detekcja kandydatów za pomocą wzorca probabilistycznego.

System procesorowy:

- konfiguracja parametrów systemu wizyjnego w logice programowalnej poprzez interfejs AXI4-Lite,




Rys. 6.1. Wykozystany system kamer. Po lewej stronie znajduje się kamera wizyjna, po prawej termowizyjna Lepton.



Rys. 6.2. Widok na kompletny system do detekcji obiektów w przestrzeni multispektralnej. Obraz jest rejestrowany przez zespół kamer znajdujący się na statywie. Kamery są połączone do płytki deweloperskiej Zybo. Wynik jest prezentowany na monitorze.

- Klasyfikacja obszarów wytypowanych przez wzorzec probabilistyczny,
- Generowanie wyników.

## 6.2. Moduły w PL



Rys. 6.3. Schemat blokowy systemu detekcji.

Na rysunku 6.3 został przedstawiony ogólny schemat rozwiązania.

## 6.3. Wykorzystanie AXI-Stream do transmisji sygnału wideo.

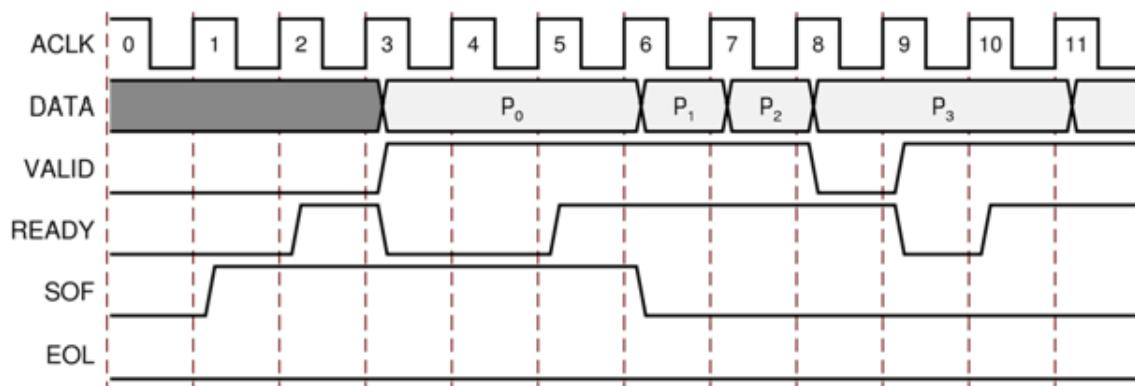
W odróżnieniu od standardowego sposobu przetwarzania strumieniowego wideo, w AXI4-Stream przesyłane są jedynie aktywne piksele. Linie synchronizacji poziomej i pionowej są odrzucane albo przekierowywane do specjalnego bloku w którym są mierzone parametry wchodzącego strumienia wizyjnego (liczba pikseli w linii, liczba aktywnych linii, czas wyciemnienia

itd.). W celu wyświetlenia obrazu, wykorzystuje się ten sam blok w celu generacji nowych sygnałów synchronizacji.

Do transmisji wykorzystane jest 6 linii: jedna linia danych i pięć kontrolno-sterujących. W nawiasach są podane ich odpowiedniki w protokole AXI4-Stream.

- *Video Data (tdata)* – linia danych o szerokości jednego (albo dwóch) pikseli. Szerokość tej linii powinna być wielokrotnością liczby osiem (16, 24, 48 itd.)
- *Valid(tvalid)* – linia określająca czy dane piksela są poprawne,
- *Ready ((tready))* – linia kontrolna informująca urządzenie master, że *slave* jest gotowy do transmisji danych,
- *Start Of Frame (tuser)* – linia, która wskazuje pierwszy piksel nowej ramki,
- *End Of Line (tlast)* – linia wskazująca ostatni piksel w linii.

Aby mógł wystąpić poprawny transfer danych linie *Valid* i *Ready* muszą być w stanie wysokim podczas rosnącego zbocza zegara. Przykładowe nawiązanie transmisji przedstawia rysunek 6.4



Rys. 6.4. Przykład rozpoczęcia transmisji Ready/Valid.

## 6.4. AXI VDMA

Wiele aplikacji wizyjnych wymaga przechowania całej ramki obrazu w celu jej dalszej obróbki np. podczas skalowania, przycinania bądź dopasowania liczby klatek na sekundę. Część programowalna układu Zynq zazwyczaj nie posiada wystarczającej liczby zasobów pamięciowych do przechowania pełnej klatki obrazu w swojej strukturze. Aby stworzyć taki bufor jest wykorzystywany mechanizm bezpośredniego dostępu do pamięci, który pozwala na przesłanie

i wczytanie danych z logiki programowalnej do pamięci RAM bez konieczności angażowania procesora. Realizuje się to poprzez IP-Core AXI VDMA. Zapewnia on przejście między interfejsem AXI4-Stream, a AXI4 Memory Map w obu kierunkach. Przed rozpoczęciem przesyłania IP-Core jest konfigurowany poprzez interfejs AXI4-Lite. Konfiguracja zawiera adres w pamięci RAM do którego ma być zapisana bądź wczytana ramka obrazu. Po wgraniu do pamięci ramki kontroler może wywołać przerwanie dla systemu procesorowego.

## 6.5. Opis modułów w PL

### 6.5.1. Kontroler kamery IR

Kamera Lepton przesyła obraz za pomocą interfejsu VoSPI (ang. *Video over Serial Peripheral Interface*). Kamera jest urządzeniem typu *slave*, zaś układ ZYNQ jest *master*. Są wykorzystywane 3 z 4 linii typowego kanału SPI: SCK (ang. *Serial Cloack* – zegar), /CS (ang. *Chip Select* – wybór układu)(aktywny stanem nikim) oraz MISO (ang. *Master In/Slave Out* – wejście master/wyjście slave). Transmisja rozpoczyna się od podania stanu niskiego przez kontroler na linii /CS. Powoduje to aktywację linii. Następnie, *master* rozpoczyna taktowanie zegarem na linii SCK. *Slave* wystawia kolejne bity danych począwszy od MSB (ang. *most significant bit*) na linię MISO. Kontroler szczytuje te bity przy każdym rosnącym zboczu zegara do 16 bitowego rejestru przesuwnego. Dane przesyłane z kamery są zorganizowane w pakiety po 164 bajty. Rozpoczęty jest nagłówkiem składającym się z 2 bajtów pola identyfikacyjnego oraz 2 bajtami sumy CRC. Pole identyfikacyjne spełnia dwa zadania. Po pierwsze, stanowi 12 bitowy numer pakietu (a zarazem numer linii obrazu), po drugie, w przypadku błędного pakietu zawiera wartość 0xFFXX (X to obojętna wartość) co wskazuje że nadchodzący pakiet powinien zostać zignorowany przez kontroler. Zawartość pakietu stanowi 160 bajtów zawierających wartości 80 pikseli linii. W systemie wykorzystywany jest format RAW14, więc każdy piksel jest przesyłany w postaci 2 bajtów zawierających 14 bitową wartość piksela. Cała ramka obrazu składa się z 63 pakietów. 60 pierwszych pakietów stanowią linie obrazu zaś ostatnie 3 są przeznaczone na telemetrię, która zawiera m.in. temperaturę FPA i obudowy, 32-bitowy licznik ramek obrazu i bity stanu. Pierwsze 3 przesłane pakiety są błędne i służą do synchronizacji transmisji. W przypadku prawidłowego pakietu kontroler szczytuje numer linii obrazu i wystawia go na wyjściu *row*. Następnie na wyjściu *data* wystawiane są wartości kolejnych 80 bitów wraz z ich pozycją na wyjściu *column*. Wysoki stan *we* informuje że dane są poprawne i powinny być zapisane. *Row* i *column* są zamieniane na adres w pamięci dwuportowej, będącą buforem ramki IR, do której są zapisywana wartość piksela z wyjścia *data*.

### 6.5.2. Transformata projekcyjna

Moduł ma na celu dopasowanie obrazu IR do RGB. W tym celu zamienia współrzędne w układzie odniesienia obrazu RGB na odpowiadające im w układzie IR. Na wejściu podawany jest strumień AXI4-Stream służący do synchronizacji ramek oraz 12 bitowe współrzędne X i Y. Moduł realizuje operacje:

$$\begin{bmatrix} u_n & v_n & n \end{bmatrix} = \begin{bmatrix} x & y & 1 \end{bmatrix} T \quad (6.1)$$

$$u = \frac{u_n}{n} \quad (6.2)$$


$$v = \frac{v_n}{n} \quad (6.3)$$

gdzie  $x, y$  to współrzędne obrazu w układzie odniesienia kamery wizyjnej,  $u, v$  to odpowiadające im współrzędne w układzie odniesienia kamery termowizyjnej.  $T$  to macierz transformacji.

Moduł wystawia na wyjściu strumień wizyjny AXI4-Stream, 12 bitowe wartości U i V oraz ich części ułamkowe w U\_fraction i V\_fraction (14 bitów). W module zostały wykorzystane 34 z 80 dostępnych w układzie Zynq modułów DSP48 do wykonania operacji arytmetycznych, z czego większość została zutylizowana przez IP-Core dzielarki dostarczony od producenta układu. Dzielenie nie odbywa się w pełni potokowo. Użyty w dzielarce algorytm High\_Radix wymaga zatrzymania strumienia na czas obliczeń. Zmniejszenie ilości instancji dzielarek pozwoliło na zaoszczędzenie pewnej ilości (jak się później okazało istotnej) zasobów logicznych. Jednak dzięki zastosowaniu wyższej częstotliwości niż zegar pikseli obrazu RGB oraz bufora (250 MHz) nie stanowi to wąskiego gardła systemu. Macierz transformacji T jest zapisana w dziewięciu 32 bitowych rejestrach i konfigurowalna poprzez interfejs AXI4-Lite. Elementy macierzy są 25 liczbami w notacji stałoprzecinkowej: 1 bit znaku 10 – część całkowita, 14 – część ułamkowa. Taka dokładność pozwala na maksymalne wykorzystanie pojedynczych modułów DSP48. Rysunek 6.5 przedstawia schemat modułu.

### 6.5.3. Interpolacja dwuliniowa

Pozwala na interpolację wartości piksela wskazanego przez koordynaty na wejściu modułu. Podobnie jak reszta systemu używa AXI4-Stream do przekazywania danych między poszczególnymi modułami. Dane na wejściu to współrzędne U i V oraz ich części ułamkowe U\_fraction ( $U_f$ ) i V\_fraction ( $V_f$ ). Moduł został wyposażony w 4 rejesty, w których przechowywane są współrzędne oraz wartości 4 ostatnio użytych pikseli. Zabieg ten znacznie redukuje liczbę potrzebnych zapytań do pamięci. Podczas powiększania obrazów jest duża szansa, że kolejne koordynaty na wejściu U, V odwołają się do tych samych czterech otaczających ich



Rys. 6.5. Schemat modułu transformacji projekcyjnej.

pikseli. Podczas transformacji dużego obrazu na mniejszy kolejne piksele obrazu wejściowego (np.(0,0), (1,0), (2,0), ...) odwołują się do przestrzeni pomiędzy czteroma pikselami małego obrazu (np. podczas zmniejszenia 10-krotnego wynikiem transformacji byłby punkty: (0,0), (0,1,0), (0,2,0), ...) więc w celu interpolacji odwoływały by się do wartości pikseli (0,0), (1,0), (0,1), (1,1)). W module jest sprawdzane, czy w pamięci są już wartości z koordynatów [U,V], [U+1,V] [U,V+1], [U+1,V+1]. Jeżeli któregoś piksela brakuje, jest on pobierany z pamięci i zapisywany w rejestrze przechowującym niepotrzebny piksel. Jeżeli wszystkie koordynaty się zgadzają, obliczana jest wartość piksela wyjściowego zgodnie ze wzorem (6.4).

$$Ir = A(1 - U_f)(1 - V_f) + B(1 - V_f) + C(1 - U_f)V_f + DU_fV_f \quad (6.4)$$

gdzie:  $A, B, C, D$  odpowiadają wartościom pikseli w [U,V], [U+1,V] [U,V+1], [U+1,V+1], a  $Ir$  to wartość wyjściowa piksela wyjściowego,

Moduł działa potokowo. W przypadku gdy jest wymagana aktualizacja rejestrów, strumień jest wstrzymywany na czas pobrania stosownych wartości z bufora ramki IR. Jeżeli koordynaty wejściowe wychodzą poza zakres obrazu termowizyjnego, to ich wartość wyjściowa odgórnie wynosi zero.

#### 6.5.4. Łączenie strumieni

Moduł posiada dwa wejścia AXIS4-Steam. Strumień RGB jest nadrzędny, i do niego jest dołączany strumień IR. Do synchronizacji została wykorzystana możliwość wstrzymania transmisji poprzez linię *tready* w interfejsie AXI4-Stream. Piksele z dołączanego obrazu są odrzucone do momentu pojawiienia się sygnału SOF, reprezentowanym przez wysoki stan linii *tuser*.



**Rys. 6.6.** Paleta kolorów użyta do wizualizacji temperatury.

Następnie w momencie pojawienia się sygnału SOF w strumieniu głównym transmisja zostaje ponownie wznowiona. Po przejściu całej ramki strumienie są ponownie synchronizowane.

### 6.5.5. Koloryzacja i nakładanie

Strumień RGBIR zostaje połączony w jeden obraz. Obraz IR zostaje poddany koloryzacji na podstawie wartości zapisanych w 12-bitowym LUT(ang. *Lookup table*). Rysunek 6.6 przedstawia użytą paletę do wizualizacji temperatury. Obrazy nakładają się w proporcjach 50 na 50. Jeżeli wartość piksela IR jest równa zero to nie jest wyświetlany. Na wyjściu jest podany 24 bitowy strumień RGB.

### 6.5.6. Obramowanie wyników

Moduł ma na celu wskazanie na obrazie lokalizacji wykrytego przechodnia, poprzez obramowanie tego obszaru ramką określonego koloru. Kolor, rozmiar i lokalizacja ramki jest zapisana w dwóch 32-bitowych rejestrach, konfigurowalnych poprzez interfejs AXI4-Lite.

### 6.5.7. Moduł DPM

Moduł został zaczerpnięty z pracy inżynierskiej autora w celu selekcji kandydatów w obrazie multispektralnym i jest opisany w rozdziale 5.5. Do detekcji wykorzystuje bezpośredni strumień pikseli kamery termowizyjnej. Pomocniczy moduł *data grabber* znajdujący się tuż za kontrolerem kamery IR ma za zadanie rozdzielenie sygnału do dwóch komponentów: bufora ramki oraz, po zbinaryzowaniu, do modułu DPM wraz z jego koordynatami. Moduł składa się z okna kontekstowego o wymiarach 16x40 px, gdzie odbywa się porównanie z macierzą wzorcową. Do każdego piksela w oknie jest przypisywana jest wartość z wzorca LPBW – jeżeli piksel jest biały, albo LPMB w przypadku czarnego. Następnie wszystkie wartości są sumowane za pomocą drzewa sumacyjnego, wynikiem czego jest wartość wyjściowa LP (ang. *Logarithmic Probability*). Jeżeli ta wartość przekroczy (ustaloną na podstawie sumy LP policzoną dla tła i parametru K) wartość progową zostaje przesłana do listy kandydatów wraz z współrzędnymi tego okna (w układzie odniesienia kamery IR). Lista kandydatów jest na bieżąco przesyłana za

pomocą AXI4-Stream do pamięci systemu procesorowego poprzez AXI DMA. Po sprawdzeniu ostatniego okna zostaje przesłany sygnał *tlast* i moduł AXI DMA wygeneruje przerwanie w systemie procesorowym. Wartość progowa binaryzacji i LP jest konfigurowalna za pomocą AXI4-Lite.

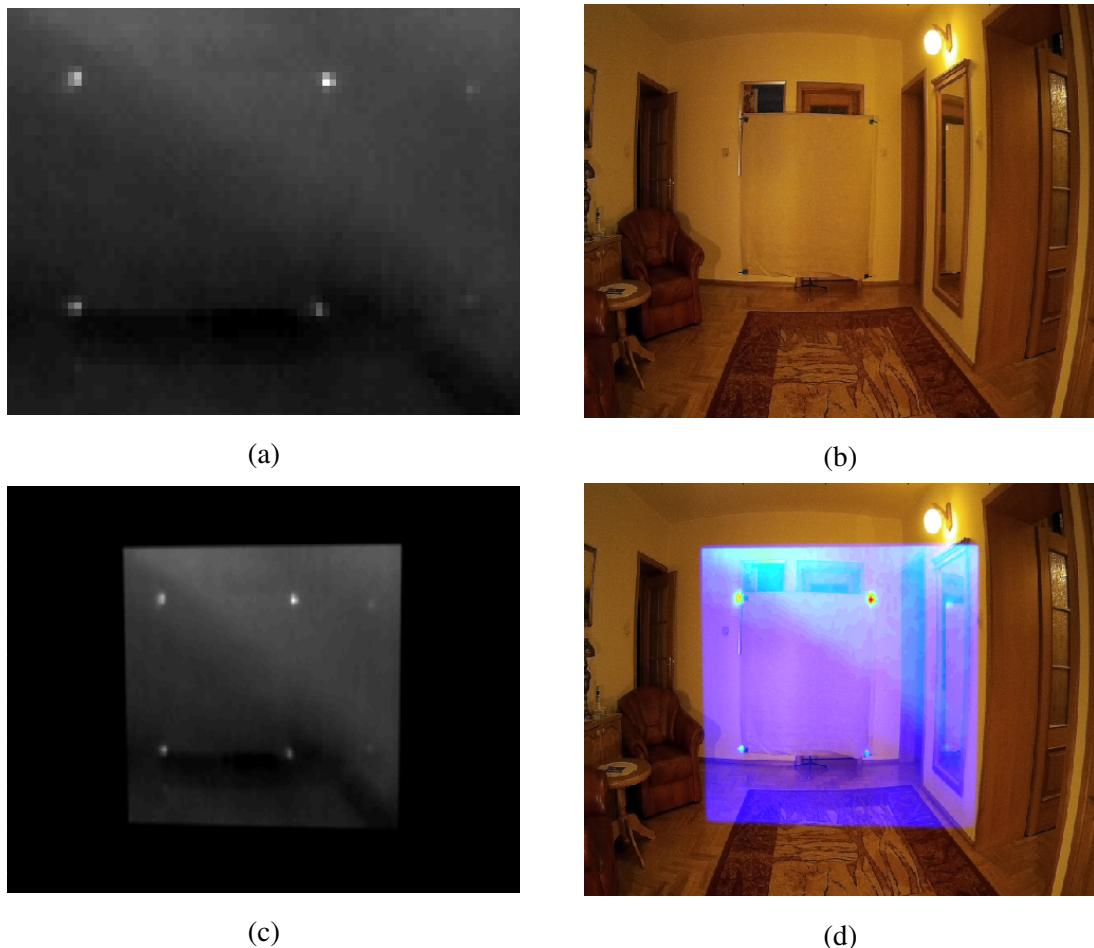
## 6.6. System procesorowy

Program działający w części procesorowej układu Zynq spełnia dwa podstawowe zadania. Po pierwsze pozwala na konfigurację modułów znajdujących się w PL za pomocą AXI4-Lite. Użytkownik za pośrednictwem konsoli może wprowadzać własne parametry dla każdego z modułów. Pozwala również na zapis na karcie SD pojedynczej klatki obrazu multispektralnego, następnego wykrytego ROI oraz ROI znajdującego się pośrodku sceny. Ta opcja ułatwia tworzenie bazy do nauczenia klasyfikatora SVM.

Drugim zadaniem jest klasyfikacja wytypowanego przez DPM kandydata. Po otrzymaniu przerwania przez moduł AXI DMA powiązany z DPM, sprawdzana jest lista kandydatów i wybierany jest ten o największej wartości LP. Współrzędne kandydata są podane w układzie odniesienia kamery IR. Po przeliczaniu ich, za pomocą macierzy transformacji projekcyjnej, i dodaniu pewnego *offsetu* w buforze ramki obrazu RGBIR jest wskazany ROI o wymiarach 80x192. Następnie jest obliczany wektor cech HOG z tego obszaru. Potem na jego podstawie odbywa się klasyfikacja przy użyciu wytrenowanego SVM. Wynik klasyfikacji jest wyświetlane w konsoli wraz z jego współrzędnymi na obrazie i wartością LP. Dodatkowo obszar ten zostanie zaznaczony zieloną ramką na wyjściu monitora. Jeżeli najlepszy kandydat nie zostanie zakwalifikowany pozytywnie przez SVM ramka przybierze kolor czerwony. Brak kandydatów wskazuje czarna ramka w miejscu ostatniej detekcji.

## 6.7. Proces kalibracji

W celu kalibracji, zostaje wykonane zdjęcie specjalnej planszy kalibracyjnej za pomocą obu kamer (rysunki 6.7a, 6.7b). Pozwala to na identyfikację czterech punktów kalibracyjnych w obu przestrzeniach: RGB i IR. Następnie na ich podstawie zostaje obliczona macierz transformacji projekcyjnej. Na rysunku 6.7c przedstawiono obraz z kamery termowizyjnej po transformacji, który po krywa się z obrazem wizyjnym (rysunek 6.7d)



**Rys. 6.7.** Proces kalibracji: (a) obraz z kamery termowizyjnej, (b) obraz z kamery wizyjnej, (c) obraz z kamery termowizyjnej po transformacji projekcyjnej, (d) obraz z kamery termowizyjnej po transformacji projekcyjnej nałożony na obraz z kamery wizyjnej.

## 6.8. HOG i SVM

Okno decyzyjne jest podzielone na 60 komórek o wielkości 16x16 pikseli. Następnie obliczone są gradienty dla poszczególnych pikseli. Pojedynczy gradient składa się z kierunku oraz wartości wypadkowej gradientu. Wykorzystany jest histogram ważony o 9 przedziałach. Oznacza to że wartość wypadkowa gradientu jest dzielona na dwa przedziały pomiędzy którymi się znajduje w proporcjach określonych wzorem (6.6), (6.7).

$$Bin1_{dir} < G_{dir} < Bin2_{dir} \quad (6.5)$$

$$Bin1_{mag} = \frac{Bin2_{dir} - G_{dir}}{Bin2_{dir} - Bin1_{dir}} \quad (6.6)$$

$$Bin2_{mag} = \frac{G_{dir} - Bin1_{dir}}{Bin2_{dir} - Bin1_{dir}} \quad (6.7)$$

gdzie:  $G_{dir}$  to kierunek badanego gradientu,  $G_{mag}$  to wypadkowa badanego gradientu,  $Bin1_{dir}, Bin2_{dir}$  to kierunki gradientów powiązane z danym przedziałem histogramu,  $Bin1_{mag}, Bin2_{mag}$  to wypadkowa gradientu przypisana do poszczególnego z przedziału.

Dla każdej z komórek dodatkowo jest obliczana suma kwadratów wartości przedziałów historgamu. Następnie komórki są łączone w bloki 2 na 2, w obrębie których dokonywana jest normalizacja wykorzystując wcześniej obliczone sumy kwadratów. Zastosowano normalizację L2 wyrażoną wzorem (6.8).

$$norm = \sqrt{\sum_i (Bin(i)_{mag})^2 + c} \quad (6.8)$$

gdzie:  $Bin(i)_{mag}$  to wartość przedziału histogramu a  $c$  to mała wartość stała. Następnie wartości wszystkich 36 przedziałów w 4 histogramach są podzielne przez  $norm$ . Bloki nakładają się na siebie więc w pojedynczym oknie można wyodrębnić 44 bloki. Suma histogramów z wszystkich bloków tworzy 1584 elementowy wektor cech.

W celu wytrenowania klasyfikatora SVM zostało wykonane 60 obrazów – 30 pozytywnych zawierających przechodnia i 30 przedstawiają elementy tła lub niekompletnej sylwetki człowieka (np. sama ręka). Jest to klasyfikator liniowy więc do każdej z cech jest przypisana jej waga. Po zsumowaniu wszystkich wag dodawany jest *bias*. Jeżeli wynik jest większy od zera świadczy to o pozytywnym wyniku klasyfikacji.

## 6.9. Wyniki

Aby sprawdzić działanie i dokładność systemu została zaimplementowana możliwość zapisu obliczonego wektora cech na karcie SD. Następnie został obliczony przykładowy błąd względny między wektorem cech wyliczonym w pakiecie Matlab, a uzyskanym z systemu wizyjnego. Błąd oscyluje w granicy  $10^{-6}$  co czyni go marginalnym i najprawdopodobniej wynika z różnic użytych bibliotek numerycznych. Świadczy to o prawidłowym działaniu systemu. Na przebadanie jednego okna zaproponowany system potrzebuje 75ms (dla porównania te same obliczenia w pakiecie Matlab zajmują około 23 ms przy użyciu komputera z procesorem Pentium Core i7 i 8GB ramu). Dzięki zastosowaniu sprzętowego wyszukiwania ROI zadanie systemu procesorowego zostało ograniczone analizy pojedynczego ROI. Kamera termowizyjna, będąca źródłem sygnału dla wzorca probabilistycznego, pracuje z prędkością 9 klatek na sekundę co zapewnia 111 ms na analizę jednej ramy obrazu. Z racji że analiza jednego okna zajmuje 75ms powoduje iż jest możliwe sprawdzenie tylko jednego ROI na ramkę.

W tabeli 6.1 zostało przedstawione wykorzystanie zasobów logiki programowej.

**Tabela 6.1.** Wykorzystane zasoby logiki programowalnej.

Element	Wykorzystane	Dostępne	%
LUT	12583	17600	71,49
LUTRAM	617	6000	10,28
FF	19924	35200	56,60
BRAM	25,50	60	42,50
DSP	36	80	45,00
IO	43	100	43,00
BUFG	7	32	21,88
MMCМ	1	2	50,00
PLL	1	2	50,00

## **7. Podsumowanie i dalsze kierunku rozwoju**

Zgodnie z celem pracy został opracowany system detekcji przechodniów na podstawie obrazu z kamery termowizyjnej. Mając do dyspozycji kamerę Lepton o bardzo małej rozdzielczości (80x60px) zdecydowano się na wykorzystanie obrazu wizyjnego i detekcję obiektów w przestrzeni multispektralnej (RGBIR). W tym celu, zgodnie z założeniem, wykorzystano heterogenicznego układu Zynq-7000 umożliwiającego sprzętowo-programową implementację algorytmów. Zadaniem części logiki programowej (FPGA) było połączenie strumieni wizyjnych z kamer w jeden obraz multispektralny oraz określenie obszaru zainteresowania (ROI) do klasyfikacji. W celu określenia ROI został wykorzystany słabszy klasyfikator: wzorzec probabilistyczny, który został opracowany przez autora w pracy inżynierskiej. Wytypowany kandydat był następnie klasyfikowany przy użyciu deskryptora HOG i SVM. Proces ten odbywał się w systemie procesorowym układu Zynq. Drugim zadaniem systemu procesorowego była konfiguracja parametrów modułów zaimplementowanych w logice programowej oraz prezentację wyników. Dodatkowa funkcja zapisania obrazów na karcie SD dała możliwość stworzenia własnej bazy próbek do nauczenia klasyfikatora. Kamera termowizyjna pracuje z prędkością 9 klatek na sekundę i jest źródłem obrazu dla modułu odpowiedzialnego za określanie ROI. Z racji że system procesorowy potrzebuje 75ms na klasyfikację pojedynczego ROI a kolejne ramki obrazu pojawiają się co około 111ms wykonywana jest tylko jedna detekcja na klatkę. Wynik ten jest znacznie słabszy od tych uzyskanych w podobnych rozwiązaniach. W celu poprawy wyniku można by przenieść część obliczeń związaną z obliczaniem wektora cech z systemu procesorowego do logiki programowej ale nie pozwalają na to ograniczone zasoby układu FPGA.



## Bibliografia

- [1] Rikke Gade i Thomas B Moeslund. „Thermal cameras and applications: A survey”. W: *Machine vision and applications* 25.1 (2014), s. 245–262.
- [2] Ji Hoon Lee i in. „Robust pedestrian detection by combining visible and thermal infrared cameras”. W: *Sensors* 15.5 (2015), s. 10580–10615.
- [3] Louis St-Laurent, Xavier Maldaque i Donald Prévost. „Combination of colour and thermal sensors for enhanced object detection”. W: *Information Fusion, 2007 10th International Conference on*. IEEE. 2007, s. 1–8.
- [4] Soonmin Hwang i in. „Multispectral pedestrian detection: Benchmark dataset and baseline”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2015, s. 1037–1045.
- [5] Gabriel J García i in. „A survey on FPGA-based sensor systems: towards intelligent and reconfigurable low-power sensors for computer vision, control and signal processing”. W: *Sensors* 14.4 (2014), s. 6247–6278.
- [6] Frank Niklaus, Christian Vieider i Henrik Jakobsen. „MEMS-based uncooled infrared bolometer arrays: a review”. W: *Photonics Asia 2007*. International Society for Optics i Photonics. 2007, s. 68360D–68360D.
- [7] Wikipedia. *Infrared*, Wikipedia, The Free Encyclopedia. [Dostęp: 9 stycznia 2016]. 2016.
- [8] LEPTON® Long Wave Infrared (LWIR) Datasheet. Lepton. FLIR Commercial Systems. 2015.
- [9] Shanshan Zhang, Rodrigo Benenson i Bernt Schiele. „Filtered channel features for pedestrian detection”. W: *Computer Vision and Pattern Recognition (CVPR), 2015 IEEE Conference on*. IEEE. 2015, s. 1751–1760.
- [10] Alejandro González i in. „Pedestrian detection at day/night time with visible and FIR cameras: A comparison”. W: *Sensors* 16.6 (2016), s. 820.

- [11] Rodrigo Benenson i in. „Ten years of pedestrian detection, what have we learned?” W: *arXiv preprint arXiv:1411.4304* (2014).
- [12] Navneet Dalal i Bill Triggs. „Histograms of oriented gradients for human detection”. W: *Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on.* T. 1. IEEE. 2005, s. 886–893.
- [13] Timo Ojala, Matti Pietikainen i Topi Maenpaa. „Multiresolution gray-scale and rotation invariant texture classification with local binary patterns”. W: *IEEE Transactions on pattern analysis and machine intelligence* 24.7 (2002), s. 971–987.
- [14] Paul Viola i Michael Jones. „Rapid object detection using a boosted cascade of simple features”. W: *Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on.* T. 1. IEEE. 2001, s. I–I.
- [15] SR Kodituwakku i S Selvarajah. „Comparison of color features for image retrieval”. W: *Indian Journal of Computer Science and Engineering* 1.3 (2004), s. 207–211.
- [16] Pedro Felzenszwalb, David McAllester i Deva Ramanan. „A discriminatively trained, multiscale, deformable part model”. W: *Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on.* IEEE. 2008, s. 1–8.
- [17] Karol Piniarski i Paweł Pawłowski. „Efficient pedestrian detection with enhanced object segmentation in far IR night vision”. W: wrz. 2017, s. 160–165.
- [18] Frédéric Suard i in. „Pedestrian detection using infrared images and histograms of oriented gradients”. W: *Intelligent Vehicles Symposium, 2006 IEEE.* IEEE. 2006, s. 206–212.
- [19] Dominik Honegger, Helen Oleynikova i Marc Pollefeys. „Real-time and low latency embedded computer vision hardware based on a combination of FPGA and mobile CPU”. W: *Intelligent Robots and Systems (IROS 2014), 2014 IEEE/RSJ International Conference on.* IEEE. 2014, s. 4930–4935.
- [20] Songlin Piao i in. „Real-time multi-platform pedestrian detection in a heavy duty driver assistance system”. W: *Proc. Int. Commercial Veh. Technol. Symp.* 2016, s. 61–70.
- [21] Han Xiao i in. „Real-time shape and pedestrian detection with FPGA”. W: *Mechatronics and Automation (ICMA), 2015 IEEE International Conference on.* IEEE. 2015, s. 2381–2386.
- [22] Tomasz Kańska. „Wbudowany system wizyjny do detekcji pieszych w warunkach nocnych”. Akademia Górnictwo-Hutnicza im. Stanisława Staszica w Krakowie, 2016.

- [23] Tomasz Kańka, Tomasz Kryjak i Marek Gorgon. „FPGA Implementation of Multi-scale Pedestrian Detection in Thermal Images”. W: *Image Processing & Communications* 21.3 (2016), s. 55–67.